Bazy danych

BAZA DANYCH GEEKS & DRAGONS

DOKUMENTACJA

Szymon Malec, 262276
Adam Wrzesiński, 262317
Michał Wiktorowski, 262330
Weronika Zmyślona, 262284

Politechnika Wrocławska
Wydział Matematyki - Matematyka Stosowana

Contents

1 Wstęp

Niniejsza dokumentacja przedstawia proces tworzenia bazy danych sklepu Geeks & Dragons w ramach projektu na zaliczenie z kursu Bazy Danych z 2023 roku. Zadanie polegało na wysymulowaniu danych, jakie mogłyby się pojawić w bazie przykładowego sklepu, mającego w ofercie gry nieelektroniczne, który dodatkowo prowadzi wypożyczalnię gier oraz organizuje turnieje. Projekt został wykonany z wykorzystaniem języka programownaia Python.

Pierwszą częścią projektu było wykonanie schematu bazy danych, a następnie wygenerowanie losowych danych. Uzyskane dane należało eksportować do bazy i umieścić na serwerze za pomocą MySQL. Kolejna część polegała na przeprowadzeniu analizy danych z wysymulowanego zbioru i przedstawienie jej w formie raportu. Ponadto został opisany przebieg normalizacji bazy danych do postaci EKNF.

2 Schemat bazy danych

Schemat bazy danych (Rysunek 1.) uwzględnia 8 tabel przechowujących nastepujące informacje:

- **cusomer** – dane dotyczące klientów sklepu,
- **staff** – dane dotyczące pracowników sklepu,
- **games_for_sale** – dane dotyczące gier dostępnych na sprzedaż,
- **games_to_rent** – dane dotyczące gier dostępnych do wypożyczenia,
- **sale** – dane na temat sprzedaży gier,
- **rental** – dane na temat wypożyczeń gier,
- **competition** – dane dotyczące organizownych turniejów,
- **competition_results** – dane dotyczące osiągnietych wyników przez uczestników turniejów.

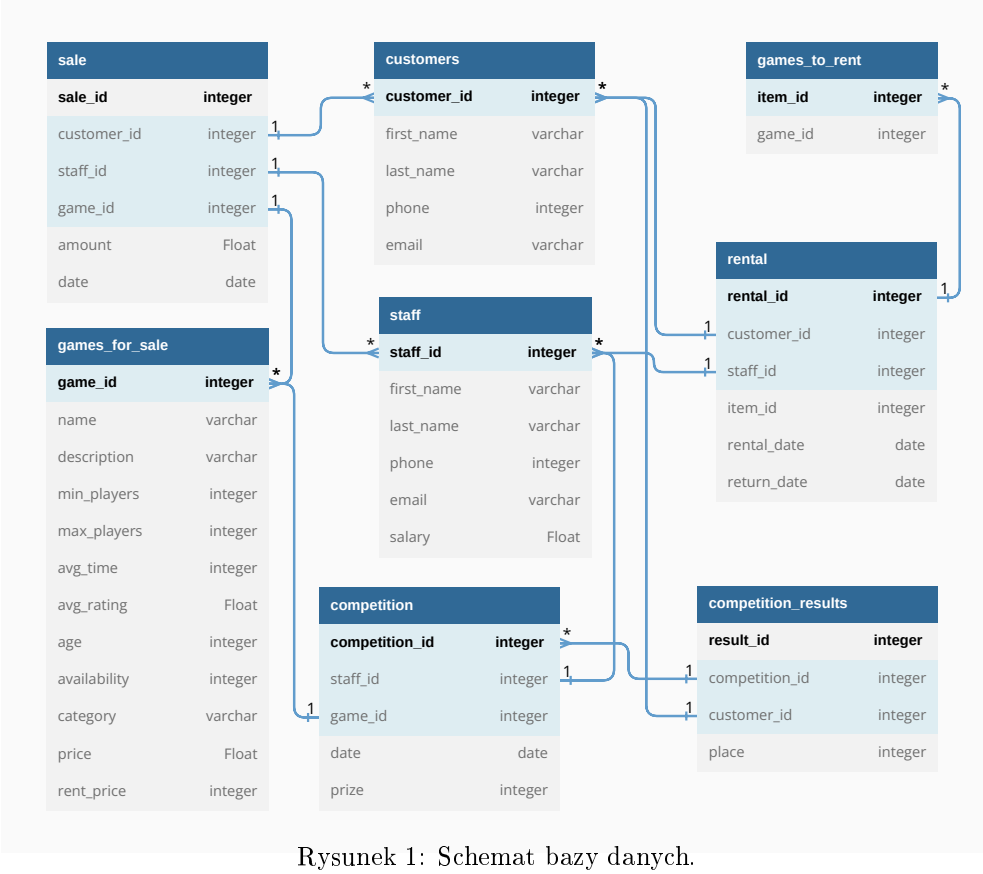

Rysunek 1: Schemat bazy danych.

3 Skryptowe wypełnienie bazy

W celu przygotowania do wypełnienia bazy losowo wygenerowanymi danymi, zostały stworzone pliki csv odpowiadające poszczególnym tabelom z bazy danych. Oprócz danych generowanych losowo, pojawiają się rownież dane rzeczywiste, co zostanie opisane w dalszej części tego rozdziału. Na sam koniec, po połączniu z serwerem, dane zostały zaimportowane do bazy.

3.1 Tabela customers

Tabela customers zawiera informacje na temat 1329 klientów, które zorganizowane są w 5 następujących kolumnach:

- **cusomer_id** – unikalne id dla każdego klienta,
- **first_name** – imię klienta,
- **last_name** – nazwisko klienta,
- **phone** – numer telefonu klienta,
- **email** – adres email klienta.

Dane w tabeli zostały wygenerowane w sposób losowy. Wartości w tabeli **cusomer_id** wygenerowane zostały na pomocą odpowiedniego przedziału dodatnich liczb całkowitych. Imiona i nazwiska klientów zostały wylosowane z odpowiednim prawdopodobieństwem korzystając z danych zamieszczonych na stronie Głównego Urzędu Statystycznego. W pierwszej kolejności został wygenerowany wektor określający płeć klienta, z odpowiednim prawdopodobieństwem występowania danej płci, na podstawie liczby ludności we Wrocławiu z podziałem na mężczyzn i kobiety. Następnie w zależności od płci zostały przypisane imiona i nazwiska z odpowiednich tabeli danych pobranych ze wspomnianej strony internetowej.

Następna kolumna zawiera losowo generowane numery kontaktowe klientów. Numer w każdym przypadku składa się z połączenia losowo wybieranego wyróżnika sieci telefonicznej (2 cyfry) oraz liczby z przedziału (1000000, 9000000). Lista dostępnych wyróżników została stworzona na podstawie informacji dostępnych na stronie Wikipedii. W ten sposób uzyskaliśmy indywidualny 9-cyfrowy numer dla każdego klienta.

Ostatnia kolumna zawiera adresy email, dla których identyfikatory użytkownika są generowane losowo na podstawie imion i nazwisk klientów. Identyfikatory adresów email składają się przykładowo:

- z połączenia imienia i nazwiska lub części nazwiska klienta,
- z połączenia imienia lub nazwiska i losowej liczby z przedziału (100, 10000).

Każdy adres email składa się również z domeny, która była losowana z listy domen stworzonej na podstawie rankingu najpopularniejszych serwisów pocztowych w Polsce dostępnego na stronie interaktywnie.com. Oczywiście, domeny były losowane z odpowiednim prawdopodobieństwem określonym według liczby użytkowników korzystających z wybranych serwisów pocztowych.

3.2 Tabela staff

Tabela staff zawiera 6 kolumn z następującymi informacjami na temat 17 pracowników sklepu:

- **staff_id** – zawiera unikalne id dla każdego pracownika,
- **first_name** – imię pracownika,
- **last_name** – nazwisko pracownika,
- **phone** – numer telefonu pracownika,
- **email** – adres email pracownika,
- **salary** – miesięczne wynagrodzenie pracownika (cena brutto).

Dane w pierwszych 4 kolumnach zostały wygenerowane w sposób analogiczny jak w przypadku tabeli customers. Nastąpiła zmiana w generowaniu adresów email dla pracowników. Są one tworzone w jednakowy sposób dla każdego pracownika – składają się z połączenia imienia i nazwiska za pomocą kropki oraz odrębnej domeny firmy @dragons.com.

Ostatnia kolumna określa miesięczne wynagrodzenie pracownika, które były losowane z listy konkretnych pensji [4310, 5140, 6530, 7280, 8320], które zostały wybrane na podstawie możliwych zarobków na stanowiskach dotyczących obsługi klienta. Losowanie odbyło się z ustalonym prawdopodobieństwem, zakładającym, że doświadczonych pracowników o większych zarobkach jest mniej.

3.3 Tabela games_for_sale

3.4 Tabela games_to_rent

3.5 Tabela sale

W tabeli znajduje się 6 kolumn:

- **sale_id** – unikalne id dla każdej sprzedaży,
- **customer_id** – unikalne id klienta,
- **staff_id** – unikalne id pracownika,
- **game_id** – unikalne id gry,
- **amount** – kwota transakcji,
- **date** – data transakcji.

Dane w tabeli obejmują 117810 transakcji. Każda sprzedaż (wiersz w tabeli) była generowana w następujący sposób:

- customer_id jest losowane z równym prawdopodobieństwem ze wszystkich dostępnych id klientów, a następnie z prawdopodobieństwem 0.83 zamieniane na NULL, co ma symulować klientów, którzy nie mają założonego konta w sklepie,
- staff_id jest losowane z równym prawdopodobieństwem ze wszystkich dostępnych id pracowników,
- game_id jest losowane z tabeli games_for_sale z prawdopodobieństwem proporcjonalnym do oceny gry (avg_rating),
- amount to wartość price z tabeli games_for_sale powiększona o losową wartość proporcjonalną do tego, jak dawno transakcja miała miejsce (gra mogła być kiedyś droższa),
- date jest losowane spośród wszystkich dni pracujących od otwarcia sklepu do dziś z prawdopodobieństwem proporcjonalnym do czasu, jaki upłynął od otwarcia sklepu (sprzedaż rośnie wraz z czasem).

3.6 Tabela rental

Tabela ta generowana jest podobnie do tabeli sale, z kilkoma różnicami. Jedną z nich jest to, że tutaj customer_id już nie zawiera wartości NULL, ponieważ klient, by wypożyczyć grę, musi mieć założone konto. Nastepnie kolumna item_id jest tworzona po wylosowaniu game_id (ponownie opieramy się na avg_rating) i dopasowaniu odpowiadającego mu item_id. W przypadku kolumny return_date losujemy czas wypożyczenia gry z rozkładu Poissona i dodajemy do rental_date.

3.7 Tabela competition

3.8 Tabela competition_results

3.9 Połączenie z bazą

Tutaj opisać co dzieje się w pliku Connection.ipynb

4 Analiza danych

Opis jak została wykonana analiza danych, jakie pytania zostały postawione...

5 Generowanie raportu

W jaki sposób generowany jest raport...

6 Technologie

Korzystanie z bibliotek pandas, sqlalchemy itp...

7 Zarządzanie plikami

Cały proces generowania danych i łączenia z bazą oraz analizy i generowania raportu został tak zorganizowany w plikach, aby mógł być odtworzony w bardzo łatwy sposób. Poniżej przedstawiona jest lista plików wraz z opisem ich zawartości:

- **Data_generation.py** – Plik generuje dane to tabel w pandas, które następnie zapisuje do plików csv w folderze database.
- **Connection.py** – Plik łączy się z bazą oraz wczytuje dane z plików csv znajdujących się w folderze database do tabel w pandas. Następnie tabele te przesyła do bazy z wykorzystaniem biblioteki SQLAlchemy.
- **Raport.rmd** – Plik generuje raport z analizą danych.

Aby uzyskać gotowy projekt należy w następującej kolejności uruchomić wynionione powyżej pliki:

1. Data_generation.py
2. Connection.py
3. Raport.rmd

8 Baza w postaci EKNF

W tej części dokumentacji zawarto listę zależności funkcyjnych dla każdej relacji oraz uzasadnienie, że baza jest w EKNF.

Tabela games_for_sale

Zależność funkcyjna: {game_id, name, description} → pozostałe kolumny

Uzasadnieniem jest fakt, że game_id jest kluczem głównym tabeli, a name i description są wartościami unikalnymi dla każdego game_id, więc każda pozostała kolumna zależy funkcyjnie od zbioru tych trzech atrybutów. Jest to więc nietrywialna zależność funkcyjna, która zaczyna się od nadklucza, a więc nie zaburza to postaci EKNF bazy.

Tabela games_to_rent

Zależność funkcyjna: item_id → game_id

Uzasadnieniem jest fakt, że item_id jest kluczem głównym tabeli, więc game_id zależy funkcyjnie od niego. Relacja ta nie zaburza postaci EKNF bazy, ponieważ tabela games_to_rent nie posiada żadnych niekluczowych zależności funkcyjnych.

Tabela sale

Zależność funkcyjna: sale_id → pozostałe kolumny

Uzasadnieniem jest fakt, że sale_id jest kluczem głównym tabeli, więc każda pozostała kolumna zależy funkcyjnie od niego. Relacja ta nie zaburza postaci EKNF bazy, ponieważ tabela games_to_rent nie posiada żadnych niekluczowych zależności funkcyjnych.

Tabela rental

Zależność funkcyjna: rental_id → pozostałe kolumny

Uzasadnieniem jest fakt, że sale_id jest kluczem głównym tabeli, więc każda pozostała kolumna zależy funkcyjnie od niego. Relacja ta nie zaburza postaci EKNF bazy, ponieważ tabela games_to_rent nie posiada żadnych niekluczowych zależności funkcyjnych.

Tabela customers

Zależność funkcyjna: {customer_id phone, email} → pozostałe kolumny

Uzasadnieniem jest fakt, że customer_id jest kluczem głównym tabeli, a phone i email są wartościami unikalnymi dla każdego customer_id, więc każda pozostała kolumna zależy funkcyjnie od zbioru tych trzech atrybutów. Jest to więc nietrywialna zależność funkcyjna, która zaczyna się od nadklucza, a więc nie zaburza to postaci EKNF bazy.

Tabela staff

Zależność funkcyjna: {staff_id phone, email} → pozostałe kolumny

Uzasadnieniem jest fakt, że staff_id jest kluczem głównym tabeli, a phone i email są wartościami unikalnymi dla każdego staff_id, więc każda pozostała kolumna zależy funkcyjnie od zbioru tych trzech atrybutów. Jest to więc nietrywialna zależność funkcyjna, która zaczyna się od nadklucza, a więc nie zaburza to postaci EKNF bazy.

Tabela competition

Zależność funkcyjna: competition_id → pozostałe kolumny

Uzasadnieniem jest fakt, że competition_id jest kluczem głównym tabeli, więc każda pozostała kolumna zależy funkcyjnie od niego. Relacja ta nie zaburza postaci EKNF bazy, ponieważ tabela games_to_rent nie posiada żadnych niekluczowych zależności funkcyjnych.

Tabela competition_results

Zależność funkcyjna: result_id → pozostałe kolumny

Uzasadnieniem jest fakt, że result_id jest kluczem głównym tabeli, więc każda pozostała kolumna zależy funkcyjnie od niego. Relacja ta nie zaburza postaci EKNF bazy, ponieważ tabela games_to_rent nie posiada żadnych niekluczowych zależności funkcyjnych.

Podsumowując, baza jest w EKNF, ponieważ każda z występujących w niej relacji nie zaprzecza tej postaci.

9 Podsumowanie

W dokumentacji został przedstawiony proces tworzenia bazy danych sklepu Geeks & Dragons od momentu tworzenia schemtu bazy, aż po analizę wykonywaną na stworzonej bazie. Przebieg powstawania bazy został podzielowny na poszczególne etapy, co ułatwiło rodzielenie zadań pośród członków grupy zajmującej sie projektem. Najtrudniejszym zadaniem podczas realizacji projektu była przede wszystkim komunikacja z prowadzącą, która nie potrafiła przekazać informacji na temat terminu oddania projektu, wprowadzając studentów w błąd. Ostatecznie grupa projektowa jest bardzo zadowolona

z efektów końcowych i ma nadzieje na wysoką, w domyśle możliwie najwyższą, punktacje za wykonane zadanie.